

Análisis de datos del detector CMS

Búsqueda del bosón de Higgs en el canal $H \rightarrow ZZ \rightarrow 2l 2q$

Objetivos

- Realizar un estudio con datos de simulaciones Monte Carlo para diseñar la estrategia de selección con la que suprimir los procesos de fondo de la señal de un bosón de Higgs.
 - Estudiar distribuciones cinemáticas que permitan discriminar señal de fondo.
- Estudiar una muestra de datos reales de CMS (en la que se ha inyectado una señal ficticia simulada) aplicando los criterios de selección determinados en el estudio con las simulaciones.
 - Comparar los datos con la predicción para los fondos y buscar un exceso atribuible a una señal.
 - Ajustar los datos a una combinación de señal y fondo, y determinar la masa, anchura, número de sucesos, significación estadística y sección eficaz de la señal de un bosón de Higgs encontrada.

Material a entregar

Breve informe con el estudio realizado incluyendo gráficas y discusión. No es necesario entregar el código del análisis de los datos.

Introducción a la práctica

Ver presentación adjunta.

- Introducción a conceptos fundamentales en análisis de datos.
- Introducción a la herramienta para análisis estadístico (Python en Google colab).
- Descripción del análisis Higgs $\rightarrow ZZ \rightarrow 2l 2q$

Descripción de los datos

Se suministran los siguientes ficheros de datos:

- Datos simulados para señales de varias masas del bosón de Higgs (350, 400 y 500 GeV)
- Datos simulados para el fondo dominante Z+Jets.
- Datos reales que incluyen los procesos de fondo y una señal ficticia simulada.
- La luminosidad integrada a la que se corresponden cada una de las muestras es la siguiente:
 - Datos: 19.7 fb^{-1}
 - Fondo Z+jets: 33.4 fb^{-1}
 - Señal MH=350 GeV: 305 fb^{-1}
 - Señal MH=400 GeV: 541 fb^{-1}
 - Señal MH=500 GeV: 1271 fb^{-1}

La estructura de los ficheros es la siguiente:

- Cada línea corresponde a un suceso.
- Cada línea contiene 17 variables:
 - momento transversal (pt), *pseudorapidity* (eta), ángulo azimutal (phi) y energía (e) de cada uno de los dos leptones (l1, l2) y de los dos jets (j1, j2). A partir de estas cuatro variables se puede reconstruir el cuadrimomento de los leptones y de los jets, la masa invariante del bosón Z leptónico (reconstruido a partir de los dos leptones), la masa invariante del bosón Z hadrónico (reconstruido a partir de los dos jets) y la masa invariante del bosón de Higgs (reconstruido a partir de los dos leptones y los dos jets).
 - *Angular likelihood discriminant* (ld)

Las unidades de momento y energía (y masa) son GeV (utilizamos unidades naturales, donde $c=1$).

Ejercicio

A. Estudio de datos de simulaciones Monte Carlo para diseñar la estrategia de selección con la que suprimir los procesos de fondo de la señal de un bosón de Higgs.

1. Estudiar para el fondo y la señal las características de las distribuciones cinemáticas de momento transverso (p_T), pseudorapidity (η) y ángulo acimutal (ϕ) de los leptones y los jets.
 - a. Discutir las características principales de las distribuciones.¹
 - b. Establecer cortes de selección en el momento transverso de leptones y jets.^{2 3 4}
2. Construir la masa invariante del bosón Z leptónico M_{ll} a partir del cuadrimomento de los dos leptones y comparar las distribuciones de la señal y el fondo.⁵
 - a. Ajustar, para la muestra de señal, la masa invariante del bosón Z leptónico a una distribución Gaussiana, o una distribución Breit-Wigner:
$$f(M) = A/[(M-m_0)^2 + (\text{width}/2)^2]$$
, y determinar su masa y su anchura.⁶
 - i. Comparar y discutir los valores obtenidos con los valores nominales para la masa y la anchura del bosón Z.
3. Construir la masa invariante del bosón Z hadrónico M_{jj} a partir del cuadrimomento de los dos jets y comparar las distribuciones de la señal y el fondo.
 - a. Establecer cortes de selección en la masa invariante del bosón Z hadrónico.
 - b. Ajustar, para la muestra de señal, la masa invariante del bosón Z hadrónico a una distribución Gaussiana, o Breit-Wigner, y determinar su masa y su anchura.
 - c. Comparar la anchura obtenida con la determinada en el ajuste de la distribución de masa invariante del bosón Z leptónico. Discutir cuál es el origen de la

¹ Sugerencia: ¿Por qué ϕ es plano? ¿Qué causan los huecos en la distribución de η a $|\eta| \sim 1.5$?

² Sugerencia: normalizar las distribuciones de las diferentes muestras a área unidad y comparar las formas para diseñar los cortes de selección.

³ Sugerencia: en principio, los cortes de selección pueden variar para distintas hipótesis de masa de la señal, pero por simplicidad adoptar un único conjunto de cortes independientes de M_H

⁴ Sugerencia: notar que existen correlaciones entre variables (p.e. p_T leptones vs p_T jets). Por simplicidad se sugiere el siguiente método secuencial: primero decidir el corte en la primera variable y estudiar la siguiente variable aplicando el corte en la primera, y así sucesivamente. Maximizar aproximadamente la significancia estadística definida como $N_{\text{Señal}}/\sqrt{N_{\text{Fondo}}}$ (notar que para calcular la significancia es necesario normalizar señal y fondo a la misma luminosidad). Un corte debe suprimir el fondo al menos cuadráticamente respecto de la señal para no perder significancia. Existen métodos más avanzados en la selección, como métodos multivariados que tienen en cuenta las correlaciones entre las variables, y métodos que utilizan la información de la forma de las distribuciones y no sólo el número de sucesos (*shape analysis vs cut-and-count*).

⁵ Sugerencia: transformar (p_T, η, ϕ) en (p_x, p_y, p_z) y construir la masa invariante a partir de $M^2 = E^2 - P^2$

⁶ Sugerencia: Incluir en el resultado los errores en los parámetros determinados en el ajuste. Una desviación significativa ($> \sim 3$ sigmas) del valor nominal indica un error sistemático (p.e. en la calibración del momento de los leptones debida a alineamiento imperfecto, correcciones pérdida de energía, etc)

diferencia.⁷

4. Estudiar la distribución de “*angular likelihood discriminant*”.
 - a. Establecer un corte de selección en ese observable.
5. Calcular para una de las muestras de señal (p.e. $M_H=400$) y para el fondo las eficiencias de los cortes. Aplicar los cortes de manera secuencial, uno tras otro, y determinar la eficiencia relativa de cada corte (número de sucesos tras el corte en cuestión dividido por el número de sucesos tras todos los cortes anteriores) y la eficiencia acumulada (número de sucesos tras todos los cortes (incluido el corte en cuestión), dividido por el número de sucesos antes de ningún corte).⁸

B. Estudio de una muestra de datos reales de CMS (en la que se ha inyectado una señal ficticia simulada) aplicando los criterios de selección determinados en el estudio con las simulaciones.

1. Representar para los datos la distribución de masa invariante M_{ljj} del objeto formado por los dos leptones y los dos jets (el bosón de Higgs en el caso de la señal) antes de aplicar ningún corte de selección.^{9 10 11}
 - a. Observar que no se aprecia la presencia de ninguna señal como un exceso por encima del comportamiento exponencial del fondo.
 - b. Comparar los datos con la predicción de la simulación para el fondo, representando M_{ljj} para los datos y para el fondo en una misma figura.¹²
 - c. Añadir en la figura de M_{ljj} la distribución para la señal. Comprobar que el número de sucesos esperado para la señal es muy pequeño comparado con el fondo.¹³

⁷ Sugerencia: resolución.

⁸ Ejemplo:

	Sucesos Señal	Sucesos Fondo	Efic. Rel. Señal	Efic. Acum. Señal	Efic. Rel. Fondo	Efic. Acum. Fondo
Sin cortes	100	1000	1	1	1	1
Corte 1	50	200	0.5	0.5	0.2	0.2
Corte 2	40	50	0.8	0.4	0.25	0.05

⁹ Sugerencia: sumar el cuadrimomento de los dos leptones y los dos jets y calcular la masa invariante a partir de (p_x, p_y, p_z, E) como $M^2 = E^2 - P^2$

¹⁰ Nota: ésta será la distribución discriminante final para establecer la existencia de una señal sobresaliendo por encima de la predicción para el fondo.

¹¹ Sugerencia: representar los errores estadísticos como $\pm \sqrt{N_{\text{bin}}}$.

¹² Sugerencia: normalizar el fondo a la luminosidad de los datos.

¹³ Nota: la señal tiene una forma resonante, con cierta anchura, que es la convolución de la anchura natural ($\text{width}(M_H=350) \sim 15$ GeV, $\text{width}(M_H=500) \sim 68$ GeV) y la resolución. Cuanto mayor es la anchura de M_{ljj} para la señal, más extendida está y más difícil de detectar ya que entra más background no resonante en esa

2. Representar para los datos la distribución M_{ijj} aplicando los cortes de selección diseñados en el apartado A del ejercicio.
 - a. Ajustar la distribución a una suma de componente exponencial (fondo) y componente Gaussiana (señal) dejando como parámetros libres las normalizaciones de las dos componentes, la tasa de decrecimiento de la exponencial, la media y anchuras de la gaussiana.^{14 15}
 - i. Determinar la masa (M_H), anchura (σ) y número de sucesos de la señal (N_S).
 - ii. Calcular el número de sucesos de fondo (N_B) en un rango $[M_H-2\sigma, M_H+2\sigma]$ y determinar la significación estadística de la señal definida como $N_S/\sqrt{N_B}$.
 - b. Medir la sección eficaz de la señal descubierta.
 - i. La expresión para calcular la sección eficaz viene dada por $\sigma = N^{señal} / (LB\epsilon)$, donde:
 - $N^{señal}$ es el número de sucesos seleccionados de la señal en los datos (determinado a través del ajuste del apartado anterior),
 - L es la luminosidad de los datos ($L=19.7 \text{ fb}^{-1}$)
 - B es la fracción de desintegración del bosón de Higgs al canal estudiado ($H \rightarrow ZZ \rightarrow 2l 2q$) ($B=0.028$)¹⁶
 - ϵ es la eficiencia de reconstrucción y selección de sucesos de señal determinada usando la simulación: $\epsilon = N_c/N_i$ donde N_c es el número de sucesos de señal en la simulación tras todos los cortes, y N_i es el número de sucesos simulados inicialmente; $N_i=200000$ para la simulación que estamos utilizando¹⁷
 - c. Comparar los datos con la predicción de la simulación para el fondo y la señal (aplicando a fondo y señal los mismos cortes de selección que a los datos reales). Representar M_{ijj} para los datos, fondo y señal en una misma figura,

ventana. La sección eficaz de producción de H decrece con M_H y también es más difícil de detectar, aunque el fondo también es menor.

¹⁴ Sugerencia: para que el ajuste converja normalmente es necesario suministrar parámetros iniciales próximos a los finales. Para ello representar la función del ajuste con los parámetros iniciales y comparar con la distribución de datos.

¹⁵ Sugerencia: limitar el ajuste a la región de M_{ijj} con caída exponencial, tras el máximo de la distribución.

¹⁶ En el canal de desintegración $H \rightarrow ZZ \rightarrow 2l 2q$, para una masa de H cercana a 400 GeV, la fracción de desintegración $H \rightarrow ZZ$ es 0.3, la fracción de desintegración $Z \rightarrow 2q$ es 0.7, y la fracción de desintegración $Z \rightarrow 2l$ (con l =electrón o muon) es 0.067. Teniendo en cuenta que existen 2 posibilidades para obtener el mismo estado final $2l 2q$ ($Z_1 \rightarrow 2l, Z_2 \rightarrow 2q$ y $Z_1 \rightarrow 2q, Z_2 \rightarrow 2l$), la probabilidad de desintegración de H al estado final $2l 2q$ es: $2 \cdot 0.3 \cdot 0.7 \cdot 0.067 = 0.028$ (2.8%).

¹⁷ La eficiencia de reconstrucción y selección de la señal se calcula teniendo en cuenta todos los cortes de selección y también todas las ineficiencias de reconstrucción del detector. Esto último no lo sabéis, por eso os doy el número inicial de sucesos simulados (200000) antes de reconstruir las partículas en el detector. Si por ejemplo, de cada 100 sucesos que se producen con un bosón de Higgs, el detector solo reconstruye 80, y luego los cortes de selección eliminan la mitad de esos 80, acabamos observando 40 sucesos de los 100 que se han producido. La eficiencia sería 40/100, y debemos corregir la sección eficaz (relacionada con la probabilidad de producción) por ese efecto.

normalizando las contribuciones de las simulaciones a la luminosidad de los datos.

- d. Calcular con la simulación de la señal, correspondiente a la masa medida en los datos, el número de sucesos esperados tras los cortes y comparar con el número de sucesos extraído en el ajuste¹⁸.

¹⁸ En este apartado se pretende ver si la predicción del número de sucesos de bosón de Higgs para la masa encontrada se corresponde con el número de sucesos observado en los datos (obtenido en el ajuste). Para ello hay que coger la simulación de la señal correspondiente a la masa encontrada, normalizar la simulación a la luminosidad de los datos (multiplicar por el factor $Lumi_datos/Lumi_MC_señal$), aplicar todos los cortes (los mismos que se han aplicado a los datos) y contar el número de sucesos obtenido.